



PROJET DE SÉRIE TEMPORELLE

Dan ALLOUCHE

1 Les données


Nous allons ici étudier l'indice corrigé des variations saisonnières et des jours ouvrés de la production industrielle pharmaceutique en France. L'indice est exprimé en base 100 en 2015. Cette base de données représente bien une série temporelle : une suite d'observations (IPI) d'un phénomène (production industrielle pharmaceutique en France) indicé par un temps (mensuel).

Selon l'INSEE, les indices de la production industrielle permettent de suivre l'évolution mensuelle de l'activité industrielle de la France et de la construction. Ils sont utilisés notamment pour l'élaboration des comptes trimestriels français. Les calculs de ces indices sont soumis à des règlement européens.

L'industrie pharmaceutique est responsable du développement, de la production et de la commercialisation des médicaments et d'autres produits pharmaceutiques. Ainsi, son importance en tant que secteur global est indiscutable.

Ici on observe les indices de production industrielle entre janvier 2010 et mars 2020. Le but de notre étude est de modéliser cette suite d'observations (par un modèle ARIMA) et ainsi de pouvoir prédire les valeurs futures.

Quel que soit l'objectif de l'étude, il faut commencer par l'exploration de la série. On examine donc différents types de graphiques offerts par R : ils permettent de comprendre la structure d'une série temporelle et de guider sa modélisation éventuelle. Le premier graphique à utiliser pour l'examen d'une série est son chronogramme :




On note une croissance du niveau moyen de la série.

La croissance du niveau moyen de la série nous montre que la série temporelle présente une tendance : il est naturel de considérer un modèle de la forme :

$$Y_t = m_t + Z_t$$

où Y_t correspond à l'IPI à la date t , m_t une fonction non constante de t appelée tendance et (Z_t) une série d'espérance nulle. La série étant corrigé des variations saisonnières il est donc ici inutile de considérer un caractère saisonnier. Cette décomposition de la série est appelé décomposition additive.

Ainsi, (Y_t) n'est pas stationnaire. On pourrait ici estimer la tendance par régression linéaire, ou par des méthodes d'estimation non paramétrique comme la méthode d'estimation par noyau par exemple. Mais on va utiliser une autre technique : on ne va pas estimer la tendance mais plutôt l'éliminer à l'aide de l'opérateur de différenciation. Le chronogramme de $(\nabla Y_t) = (Y_t - Y_{t-1})$ nous montre que la variabilité semble augmenté avec le temps ; la série présente une certaine forme d'hétéroscédasticité que l'on va corriger par une transformation logarithmique. Voici le chronogramme de la serie après transformation $((X_t) = (\nabla \log(Y_t)))$



Cette série semble stationnaire. Vérifions cette propriété à l'aide de tests statistiques. Il en existe plusieurs. Dans les modèles autorégressifs on distingue le cas où le polynôme d'autorégression a une racine égale à 1 ce cas correspond au cas non stationnaire, le premier test (test de racine unité) considère l'hypothèse nulle "1 est racine du polynôme d'autorégression". Le plus utilisé de ces tests est le test ADF (*Augmented Dickey-Fuller*). La serie (Y_t) ne montre ni dérive ni tendance.

Le principe du test ADF dans ce cas est le suivant :

1. estimer $\Delta X_t = \pi X_{t-1} + \alpha_1 \Delta X_{t-1} + \dots + \alpha_{p-1} \Delta X_{t-p+1} + \varepsilon_t$
2. on teste $H_0 : \pi = 0$
contre $H_1 : \pi < 0$
3. deux statistiques pour ce test :

- $(n-p) \frac{\hat{\pi}}{1 - \hat{\alpha}_1 - \dots - \hat{\alpha}_{p-1}}$
- La statistique de Student

4. Les valeurs critiques de la première statistique ont été donné par Fuller(1996)

Nous utilisons la fonction `ur.df()` de `urca` qui effectue les tests ADF ; dans notre cas (ni tendance ni dérive) il faut utiliser le paramètre `type='none'`. Le seul problème ici est qu'on modélise la série par un modèle AR(p) mais p nous est inconnu. Nous commençons donc par choisir une valeur de p arbitrairement grande et la diminuons tant que le coefficient du plus grand retard n'est pas significatif. Dans notre cas on arrive à p=4 (lag=3).

La fonction `adfTest()` nous donne directement la valeur de la statistique et la p-value : elle est inférieure à 0.01 donc on rejette H_0 à un niveau $\alpha = 1\%$ ainsi le test rejette la présence d'une racine unité dans le modèle : on rejette l'hypothèse que (X_t) est non stationnaire.

On peut aussi utiliser le test de KPSS grâce à la fonction `ur.kpss()`. Dans ce test, l'hypothèse nulle est : la série est stationnaire (à une tendance ou à une moyenne près). On rejette H_0 lorsque la statistique dépasse une valeur critique (les valeurs critiques sont données en sortie de la fonction).

```
#####
# KPSS Unit Root Test #
#####

Test is of type: mu with 4 lags.

value of test-statistic is: 0.2076

Critical value for a significance level of:
      10pct   5pct  2.5pct  1pct
critical values 0.347 0.463 0.574 0.739
```

On ne rejette pas H_0 même à 10%.

Les deux tests semblent nous indiquer que la série transformée et différenciée est bien stationnaire confirmant notre intuition.

2 Modèle ARMA

(X_t) est un ARMA(p,q) canonique si elle est stationnaire au second ordre et vérifie $\forall t$:

$$\Phi_\theta(B)X_t = \Psi_\theta(B)\varepsilon_t$$

Où :


1. $(\varepsilon_t) \sim BB(0, \sigma^2)$ (c'est l'innovation linéaire de (X_t))
2. $\theta = (\phi_1, \dots, \phi_p, \psi_1, \dots, \psi_q)$
3. B est l'opérateur retard
4. $\Phi_\theta(z) = 1 - \phi_1 z - \dots - \phi_p z^p$ et $\Psi_\theta(z) = 1 - \psi_1 z - \dots - \psi_q z^q$ n'ont pas de racines en communs et ont leurs racines en dehors du cercle unité

Lorsqu'on suppose que (X_t) est un ARMA(p,q) canonique et que l'on observe $(X_1, \dots, X_T)$ (avec T=122 dans notre cas; T est assez grand pour considérer l'approximation asymptotique valable) on estime le paramètre inconnu $\theta \in \Theta$ (où Θ est l'ensemble des θ vérifiant le point 4) par l'estimateur des moindres carrés ordinaires :

- $\forall 0 < t \leq T$ on approxime $\varepsilon_t(\theta) = \Psi_\theta(B)^{-1} \Phi_\theta(B)X_t$ par : $e_t(\theta) = X_t - \sum_{i=1}^p \phi_i X_{t-i} + \sum_{i=1}^q \psi_i e_{t-i}(\theta)$
où $e_0 = e_{-1} = \dots = e_{-q+1} = X_0 = \dots = X_{-p+1} = 0$
- $\hat{\theta}_T = \underset{\theta \in \Theta}{\operatorname{argmin}} \{Q_T(\theta) = \frac{1}{T} \sum_{i=1}^T e_i^2(\theta)\}$

Par défaut R estime θ par maximum de vraisemblance il faut utiliser l'option `method='CSS'` pour obtenir l'estimateur des moindres carrés ordinaires.

La première étape consiste à chercher les ordres maximums vraisemblables de p et q par l'étude des auto-corrélogrammes partiel et total :



Ainsi en notant $\hat{\rho}$ l'autocorrélation empirique et $\hat{r}$ et l'autocorrélation partielle empirique :

- Si (X_t) est MA(q) (ARMA(0,q)) alors : $\forall h > q \sqrt{T} \hat{\rho}(h) \xrightarrow{d} \mathcal{N}(0, 1 + 2\rho^2(1) + \dots + 2\rho^2(q))$ les bornes de significativité à 95% sont donc $\pm 1.96 \sqrt{1 + 2\rho^2(1) + \dots + 2\rho^2(q)}/\sqrt{T}$ (R utilise les bornes plus contraignantes $\pm 1.96/\sqrt{T}$)
- Si (X_t) est un AR(p) (ARMA(p,0)) avec bruit blanc indépendant alors : $\forall h > p \sqrt{T} \hat{r}(h) \xrightarrow{d} \mathcal{N}(0, 1)$

Les fonctions d'autocorrélations totales sont significatives jusqu'à q=5 et les autocorrélations partielles jusqu'à p=4 : les modèles possibles sont tous les ARMA(p,q) avec $p \leq 4$ et $q \leq 5$.

La deuxième étape consiste à sélectionner les meilleurs modèles à l'aide de critère à minimiser : AIC/BIC. Pour cela on utilise la fonction `auto.arima()` de `forecast` : elle utilise une variante de l'algorithme de Hyndman-Khandakar qui combine tests de racine unitaire, minimisation d'un critère pour obtenir un modèle. La fonction comporte énormément de paramètres importants.

Notons que nous avons utilisé dans notre cas les paramètres nécessaires pour comparer les modèles possibles (d=0,D=0,max.p=4,max.q=5,max.order=9), le paramètre `ic` demande le critère à minimiser, `seasonal` demande si les modèles saisonniers doivent être explorés (FALSE dans notre cas), `allowmean` si une moyenne doit être considérée (FALSE), on met `stepwise=FALSE` afin de comparer tous les modèles et ne pas utiliser la technique de `stepwise` sélection.


Le modèle obtenu à l'aide du critère AIC est ARMA(1,5)


Le modèle obtenu à l'aide du critère BIC est ARMA(0,1)

Maintenant nous devons vérifier si les résidus estimés $\hat{\varepsilon}_t = \varepsilon_t(\hat{\theta}_T)$ sont bien des bruits blancs pour pouvoir justifier la validité des modèles. Pour cela on teste dans un premier temps la blancheur des résidus par l'affichage de leur fonction d'autocorrélation : l'autocorrélation empirique d'ordre h des résidus estimés vérifie asymptotiquement $\hat{\rho}_{\hat{\varepsilon}}(h) \sim \mathcal{N}(0, v)$ avec $v < 1/T$ pour h petit $v \approx 1/T$ pour h grand.

On utilise aussi le test Portemanteau modifié de Ljung-Box : la statistique est $Q = T(T+2) \sum_{h=1}^H \frac{1}{T-h} \hat{\rho}_{\hat{\varepsilon}}^2(h)$, la loi asymptotique de Q est approximativement une loi du χ^2 à H-p-q degrés de liberté si le bruit est indépendant. L'adéquation du modèle est donc rejetée au niveau α si $Q > \chi_{1-\alpha}^2(H-p-q)$.

On affiche le graphe des résidus ainsi que son AFC et son PACF à l'aide de la fonction `xy.acfb()` :





Les autocorrélations des résidus du modèle ARMA(1,5) ne sont pas significatifs : un argument fort en faveur de la blancheur des résidus. Cependant les résidus du modèle ARMA(0,1) présentent des autocorrélations significatives.

Formellement réalisons le test Portemanteau modifié de Ljung-Box à l'aide de la fonction `Box.Test.2()`, les résultats confirment nos intuitions : pour le modèle ARMA(1,5) les p-values sont très élevées (supérieur à 0.9, l'hypothèse H_0 correspond à l'absence d'auto-corrélation des erreurs) confirmant ainsi la blancheur des résidus. Cependant pour le modèle ARMA(0,1) les p-values avec H entre 5 et 8 sont inférieurs à 0.1 pour H=5 on obtient même 0.0296 le test est significatif et on rejette la blancheur des résidus.

On retient donc le modèle ARMA(5,1), vérifions maintenant si le modèle peut être simplifié par des tests de significativité des coefficients estimés : on effectue un test de Student. La fonction `t_stat()` de **caschronos** permet de calculer les statistiques de Student et les p-values associé :

```

              ar1      ma1      ma2      ma3      ma4      ma5
t.stat -2.993898 -0.365086 -2.990716 -0.740146 -1.961263 3.723202
p.val   0.002754  0.715048  0.002783  0.459212  0.049848 0.000197

```

La valeur absolue des statistiques de student associé aux coefficients ϕ_1 et ψ_5 sont supérieurs à 1.96 donc les coefficients sont significatifs. Cependant on peut retirer de notre modèle ψ_1 , ψ_3 et ψ_4 (le choix d'enlever ψ_4 peut paraître étrange mais la statistique associée est extrêmement proche de -1.96 la loi étant asymptotique par simplification du modèle on décide de la retirer. De plus lorsque l'on conserve ce coefficient on remarque qu'après avoir supprimé les deux autres la statistique de student du coefficient devient -1.78 : ϕ_4 n'est donc plus significative). Après avoir comparé les σ^2 (ils sont significativement identiques) et avoir testé la blancheur des résidus du nouveau modèle on en conclut que la suppression de la moyenne mobile sur l'ordre 1,3 et 4 ne diminue pas la qualité de l'ajustement. Enfin tous les coefficients sont significatifs :

```

              ar1      ma2      ma5
t.stat -6.542247 -4.384434 3.712709
p.val   0.000000  0.000012 0.000205
~ |
Series: X
ARIMA(1,0,5) with zero mean

Coefficients:
              ar1      ma1      ma2      ma3      ma4      ma5
              -0.5611      0      -0.4339      0      0      0.2893
s.e.           0.0858      0      0.0990      0      0      0.0779

sigma^2 estimated as 0.002134: part log likelihood=203.03

```

Le modèle a été estimé avec l'option `method='CSS'` c'est donc les coefficients des MCO. Le modèle est donc :

$$X_t - 0.5611X_{t-1} = \varepsilon_t - 0.4339\varepsilon_{t-2} - 0.2893\varepsilon_{t-5}$$

Donc $((1-B)\log(Y_t))$ est un ARMA(1,5) causal et donc $(\log(Y_t))$ est un ARIMA(1,1,5).

3 Prévision

On cherche à prédire X_{T+1} et X_{T+2}
 Supposons que (X_t) suive bien le modèle choisi c'est à dire que : $\forall t$:

$$\Phi_\theta(B)X_t = \Psi_\theta(B)\varepsilon_t$$

Où :

1. $(\varepsilon_t) \sim BB(0, \sigma^2)$ (c'est l'innovation linéaire de (X_t))
2. $\theta = (\phi_1, \psi_2, \psi_5)$
3. B est l'opérateur retard
4. $\Phi_\theta(z) = 1 - \phi_1 z$ et $\Psi_\theta(z) = 1 - \psi_2 z^2 - \psi_5 z^5$ n'ont pas de racines en communs et ont leurs racines en dehors du cercle unité

On cherche la meilleure combinaison linéaire de $X_T, X_{T-1}, \dots$ pour prévoir X_{T+h} (on l'a notera $\hat{X}_{T+h|T}$).

On va utiliser la représentation $AR(\infty)$ de l'ARMA : $\varepsilon_t = \Psi_\theta(B)^{-1} \Phi_\theta(B) X_t \iff X_t = \varepsilon_t + \sum_{i \in \mathbb{N}^*} d_i X_{t-i}$

Il en vient que : $\hat{X}_{T+h} = \sum_{i \in \mathbb{N}^*} d_i \hat{X}_{T+h-i|T}$ avec naturellement $\hat{X}_{t|T} = X_t \forall t \leq T$


En utilisant la représentation $MA(\infty)$: $X_t = \Phi_\theta(B)^{-1} \Psi_\theta(B) \varepsilon_t = \varepsilon_t + \sum_{i \in \mathbb{N}^*} c_i \varepsilon_{t-i}$ on remarque que :

$$X_{T+h} - \hat{X}_{T+h} = \varepsilon_{T+h} + \sum_{j=1}^{h-1} c_j \varepsilon_{T+h-j}$$

Si on suppose que (ε_t) est un bruit blanc gaussien alors : $X_{T+h} - \hat{X}_{T+h|T} \sim \mathcal{N}(0, \sigma^2(1 + \sum_{j=1}^{h-1} c_j^2))$

Nous observons uniquement $(X_1, \dots, X_T)$. Nous avons vu comment estimer θ ; en remplaçant θ par $\hat{\theta}_T$ on estime $\hat{c}_i$ et $\hat{d}_i$, puis nous estimons $\hat{X}_{T+h|T}$ par $\hat{X}_{T+h} = \sum_{i=1}^{T+h-1} \hat{d}_i \hat{X}_{T+h-i}$. En supposant que (ε_t) est un bruit blanc gaussien on en déduit l'intervalle de prévision de niveau α : $[\hat{X}_{T+h} \pm \Phi^{-1}(1 - \alpha/2) \hat{\sigma} \sqrt{1 + \sum_{j=1}^{h-1} \hat{c}_j^2}]$ où Φ^{-1} est la fonction quantile d'une loi normale centrée réduite.

On utilise la fonction `forecast()` de **forecast** pour effectuer des intervalles de prévision :



La dernière question fait intervenir le concept de causalité introduit par Granger : (Y_t) cause (X_t) au sens de Granger si (Y_t) est utile pour prédire (X_t) . Plus particulièrement on cherche à savoir si (Y_t) cause instantanément (X_t) : c'est à dire que Y_{T+1} est utile pour prévoir X_{T+1} à la date T.

Comme (Y_t) et (X_t) sont stationnaires la propriété est vérifiée ssi : $\hat{X}_{T+1|(X_u, Y_u; u \leq T) \cup (Y_{T+1})} \neq \hat{X}_{T+1|(X_u, Y_u; u \leq T)}$

Une autre condition nécessaire et suffisante est que les innovations $X_t - \hat{X}_{t|(X_u, Y_u; u \leq t-1)}$ et $Y_t - \hat{Y}_{t|(X_u, Y_u; u \leq t-1)}$ soient non corrélés.

4 Annexe

```
require(caschrono)
require(urca)
require(fUnitRoots)
require(forecast)

#On importe la base de données
path="C:/Users/danal/OneDrive/ENSAE/2A/S2/Serie Temp/Projet/dataset.csv"
data=read.csv(path,sep=';',skip=2,col.names = c('Time','Y','A'))

#Affichage du chronogramme de la serie temporelle
Y=ts(data$Y,frequency = 12,start = c(2010,1))
autoplot(Y,xlab='Tems',ylab="Indice de la production industrielle",col="red")

#Différenciation de la serie et affichage de son chronogramme
X1=diff(Y,1)
autoplot(X1,xlab='Tems',ylab="Serie différenciée",col="red")
X=diff(log(Y),1)
autoplot(X,xlab='Tems',ylab="X",col="red")

#Test ADF pour verifier la stationnarité de la serie; type='none' pour une serie qui ne montre ni dérive ni tendance
adf1=ur.df(X,lags=0,type = 'none')
summary(adf1)
##pour un affichage de la statistique et de la p-value
adfTest(X,lag=3,type='nc')

#test KPSS pour verifier la stationnarité de la serie
summary(ur.kpss(X,type='mu'))

##Affichage des autocorrélations (partielles et totales) pour determiner p* et q*
acf(X)
pacf(X)

##Choix du modèle
bestaic=auto.arima(X,d=0,D=0,max.p = 4,max.q = 5,max.order=9,ic='aic',seasonal = F,allowmean = F,trace = T,stepwise = F,method = 'CSS',test = NULL)
bestbic=auto.arima(X,d=0,D=0,max.p = 4,max.q = 5,max.order=9,ic='bic',seasonal = F,allowmean = F,trace = T,stepwise = F,method = 'CSS',test = NULL)

##Validation des modèles
xy.acfb(residuals(bestaic))
xy.acfb(residuals(bestbic))
retaic=seq(7,30,1)
Box.test.2(residuals(bestaic),retaic,type="Ljung-Box",fitdf=6,decim=4)
retbic=seq(2,30,1)

##Significativité des paramètre estimés
t_stat(bestaic)

## on retire ma1 m3 et m4
arma=Arima(X,order = c(1,0,5),method = 'CSS',fixed = c(NA,0,NA,0,0,NA),include.mean = F)
arma
bestaic

##Validation du nouveau modèle
xy.acfb(residuals(arma))
Box.test.2(residuals(arma),seq(4,30,1),type="Ljung-Box",fitdf=3,decim=4)

##Significativité des nouveau paramètre:
t_stat(arma)

##Affichage des paramètres
arma

##intervalle de prevision
autoplot(forecast(arma,h=2,level=95))
```